

Individuell inlämningsuppgift – Machine Learning

Case: California Housing – modellering som beslutsunderlag

1) Mål & valt spår

Mål:

Kunden vill kunna göra grova värderingar av bostadsområden för att kunna planera investeringar och resurser. De vill ha ett datadrivet beslutsunderlag som visar vilka faktorer som påverkar bostadsvärden.

Valt spår:

Jag har valt Spår A där målet är att förutsäga median_house_value. Regression passar eftersom median_house_value är en kontinuerlig variabel, och det ger möjlighet att kvantitativt uppskatta bostadsvärden baserat på områdets egenskaper.

2) Kort data-insikt (EDA)

Observation 1 – Medianinkomst starkt kopplad till bostadsvärde

Korrelationsmatrisen visar att 'median_income' är starkt kopplad till 'median_house_value'. Det betyder att områden med högre medianinkomst har generellt högre husvärden. Medianinkomst är därför en viktig prediktor i modellen.

Observation 2 – Modellen kan behöva hantera outliers

I boxplotten för 'total_bedrooms' syns att kolumnen innehåller outliers. Även i analysen med PCA och KMeans upptäckte jag outliers. Extrema datapunkter /outliers kan påverka prediktionsmodellen negativt och bör hanteras.

3) Metod (ML-flöde)

Datasetet delades upp i 80 % träning och 20 % test för att utvärdera modellens prestanda på osedd data. Testdatan används bara en gång på slutet.

Följande modeller testades: Baseline (DummyRegressor) som referens, Linear Regression för linjära samband, och Random Forest för att fånga icke-linjära mönster.

Modellerna utvärderades och optimerades mot RMSE (Root Mean Squared Error). RMSE gör att modellen prioriterar att minimera de största avvikelserna, vilket är viktigt i bostadsvärdering för investering.

4) Resultat

Random Forest presterade bäst med RMSE 50 414, jämfört med Linear Regression (68 408) och Baseline (115 617). Efter tuning förbättrades Random Forest modellen marginellt till 49 272 med `n_estimators=300`, `max_depth=None`, `min_samples_split=2`, `min_samples_leaf=1`, `max_features='sqrt'`. På testdata uppnåddes RMSE 48 724, MAE 32 194 och R^2 0,819, vilket visar att modellen generaliserar väl och förklarar 82 % av variationen i bostadsvärden. RMSE motsvarar ett genomsnittligt fel på cirka 50 000 USD, vilket är rimligt för grova värderingar på områdesnivå.

5) Rekommendation

Jag rekommenderar Random Forest som modell för vidare användning. Den ger bäst prediktioner (lägst RMSE och hög R^2), hanterar icke-linjära samband och variation i datan, vilket stödjer kundens behov av att uppskatta bostadsvärden

6) Risker & begränsningar

En risk är att datakvaliteten kan påverka modellen, exempelvis om det finns saknade eller felaktiga värden i datasetet. Detta kan leda till snedvridna eller opålitliga prediktioner. En annan begränsning är generaliseringen, där modellen kan vara överanpassad till träningsdatan och prestandan på testdata kan vara sämre än förväntat. Dataläckage (data leakage) kan också inträffa om information från testdata påverkar träningen, vilket kan ge orimligt höga resultat. Slutligen kan modellen vara svår att tolka vid beslut på individnivå, då den inte förklarar de specifika faktorer som påverkar varje enskilt bostadsvärde.

7) Övervakad inlärning

Vad är övervakad inlärning?

Övervakad inlärning är en typ av maskininlärning där vi inte har någon targetvariabel. Modellen försöker istället hitta mönster, strukturer eller grupper i datan utifrån de tillgängliga features.

När är det relevant i det här caset?

I det här caset kan övervakad inlärning hjälpa oss att:

- Identifiera grupper av liknande områden (t.ex. typområden med liknande hushållsstorlek, rum, befolkning och inkomst).
- Upptäcka extrema datapunkter / outliers som kan påverka prediktionsmodellen.
- Förenkla datan med dimensionell reduktion för bättre visualisering och analys.

Vad PCA respektive klustring är till för?

PCA används för att reducera antalet variabler samtidigt som man behåller så mycket information (variance) som möjligt. Jag valde 5 komponenter som förklarar $\geq 95\%$ av variansen.

KMeans försöker dela in datapunkter i K grupper där varje punkt är nära sin klustercentrum. Det hjälper oss att identifiera naturliga grupper av områden och separera outliers. Jag valde 4 kluster baserat på elbow-metoden och silhouette score. Tre kluster representerar typiska områden. Det fjärde klustret består av 3 extrema outliers, som tydligt skiljer sig från resten av datan.

Två risker/fallgropar

1. Skalning är viktig

PCA och KMeans är känsliga för olika skalor. Alla features standardiserades innan analysen.

2. Outliers kan påverka resultat

De 3 extrema datapunkterna skulle kunna påverka negativt om man använde dem i ML-modellen.

Tolkning

Jag implementerade PCA med 5 komponenter och KMeans med 4 kluster. Visualisering visar tydligt de två stora klustren, det mindre atypiska klustret (69 datapunkter) och de extrema outliers (3 datapunkter). Vi kan se vilka områden som är "normala", vilka som avviker och vilka datapunkter som behöver hanteras innan regression.

8) Självreflektion

Jag lyckades skapa en körbar ML-lösning och oövervakad inlärning. Det svåraste är att tolka modellen, hantera outliers och undvika data leakage.

Jag tror att min inlämning motsvarar VG eftersom jag genomförde ett komplett ML-flöde (krav för G) och dessutom använde PCA och KMeans samt skriver en fördjupning i metod/analys i rapporten (krav för VG).

Fördjupning i metod/analys (VG)

Robusthet: Bästa parametrar från GridSearchCV gav ett medelvärde för CV-RMSE på cirka 49 272, med RMSE per fold: 50 598, 48 858, 48 106, 50 366 och 48 430. Standardavvikelsen mellan foldsen är 1 019, vilket är relativt lågt i förhållande till medelvärdet. Detta visar att modellen presterar stabilt över olika data-split, och resultaten är robusta. Modellen påverkas inte mycket av vilken del av datan som används som train/test.

Kritisk diskussion: Det finns risker med data leakage. Generalisering till ny data är en annan begränsning, särskilt eftersom modellen är tränad på en specifik geografisk dataset. Nästa

steg skulle kunna vara att testa modellen på ny geografisk data, experimentera med fler features och utvärdera med andra regressionsmodeller.